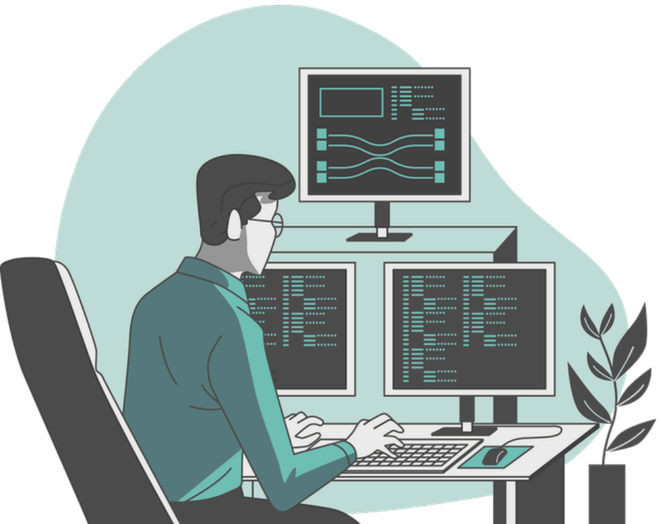
ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de HONORIS UNITED UNIVERSITIES

Plateforme Big Data d'Analyse des Tendances Médiatiques



Encadré par : Dr.Othmane Daif

Présenté par

Abdelkader Elassali	4eme AIDS Emsi
Hiba Omri	Centre

PLAN

01 Introduction

02 Problématique

03 Solution proposée

04 Objectifs du projet

05 Méthodologie

06 Conception & Analyse

07 Architecture & Technologies

08 Réalisation & Mise en œuvre

09 Perspectives d'Amélioration

10 Conclusion

01

Introduction

Introduction

- Aujourd'hui, les plateformes d'actualité génèrent un volume massif d'informations provenant de multiples sources et formats.
- Dans ce contexte, notre projet vise à concevoir une architecture distribuée capable de collecter, traiter, stocker et analyser des articles de presse en quasi temps-réel.
- La solution proposée repose sur plusieurs technologies modernes de Data Engineering, notamment Python, Kafka, MinIO, Airflow, PostgreSQL et Metabase, afin de construire un pipeline analytique scalable, automatisé et conteneurisé.
-



02

Problematique

Problématique

01

Volume:

uantité massive de données brutes.

02

Variété:

Formats web complexes (HTML, RSS)

03

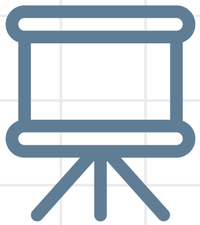
Vélocité

Besoin d'une collecte en continu.

04

Complexité

Comment orchestrer un pipeline complet sans intervention humaine ?





03

Solution proposée

Solution Proposée

01 Ingestion Kafka

Utilisation d'un bus d'événements pour gérer le flux massif de données sans perte.

02 Scraping Python

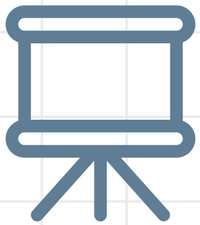
Développement d'un moteur sur mesure (BS4) pour normaliser les sources disparates.

03 Pipeline Temps-Réel

Une architecture capable de traiter l'information dès sa publication.

04 Nettoyage Automatisé

Implémentation d'une couche "Silver" pour filtrer le bruit et ne garder que le texte pur.





04

Objectifs du projet

Objectifs du Projet



Collecte Automatique

Récupération d’articles depuis plusieurs sources d’actualité.



Architecture Data Lake

Organisation des données avec une approche Medallion Bronze / Silver / Gold.



Traitement & Qualité

Nettoyage, transformation et validation des données avant analyse.



Analyse & Visualisation

réation de dashboards analytiques pour le suivi des tendances et statistiques.



05

Méthodologie

Méthodologie



Analyse des besoins

Identifier les besoins techniques et analytiques



Conception architecture

Définir les couches et les flux de données.



Implémentation

Développer chaque composant du pipeline.



Tests & Data Quality

Vérifier la qualité et la stabilité.



Itérations Successives

Améliorer progressivement le pipeline.



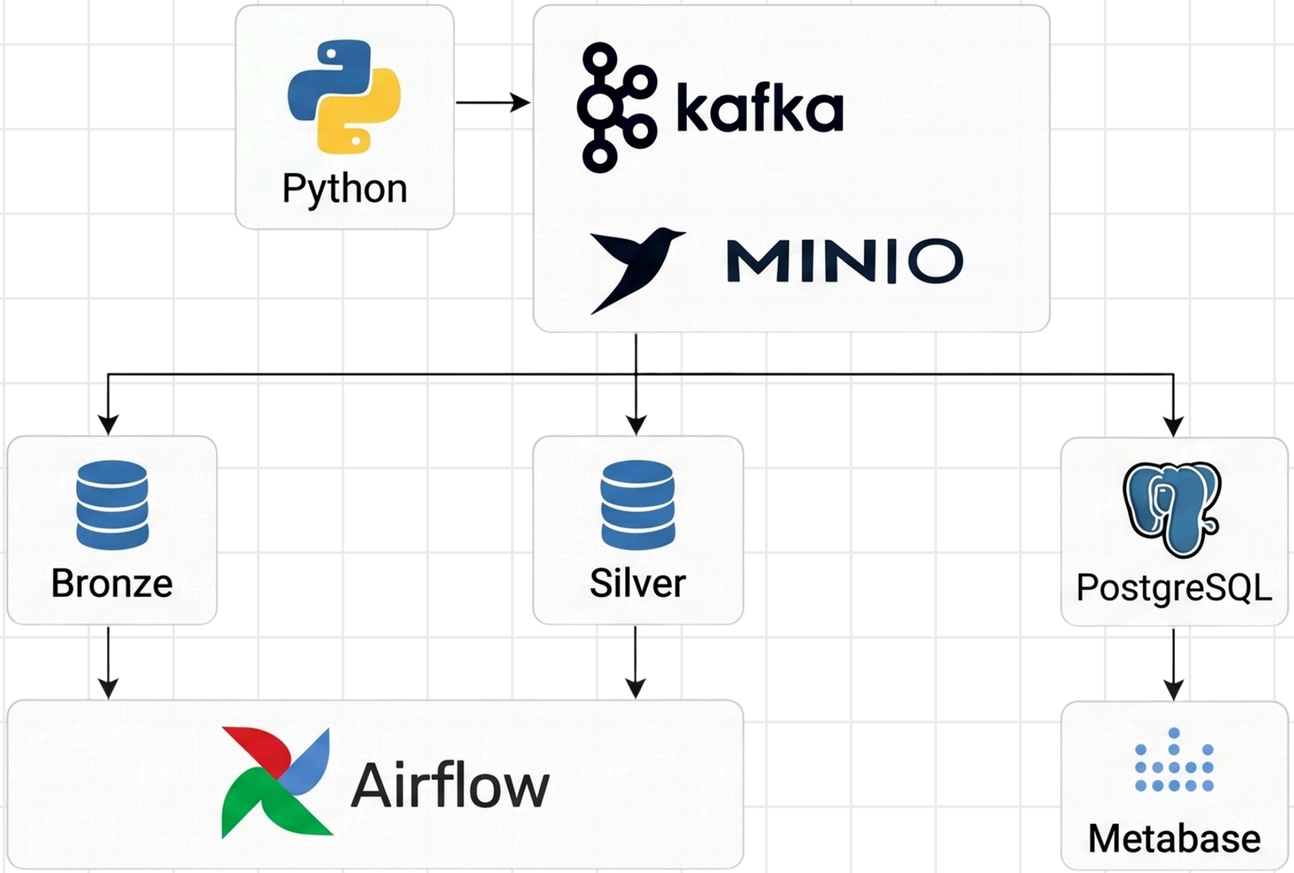
Déploiement

Mise en production conteneurisée.

06

Architecture globale




Python
kafka
MINIO
Bronze
Silver
PostgreSQL
Airflow
Metabase

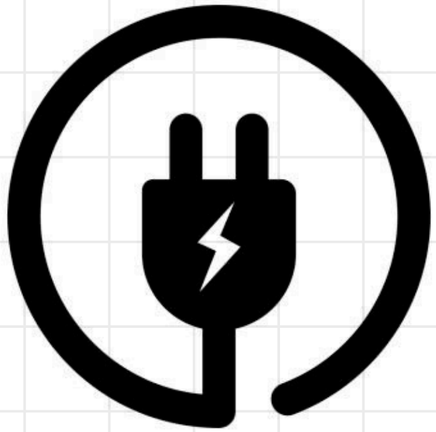
07

Stack technique

Stack technique

Python
Scraping et transformations.

PostgreSQL
Entrepôt analytique.



Kafka
Streaming des événements

Airflow
Orchestration des pipelines.

MinIO
Stockage Data Lake S3.

Metabase
Visualisation BI.Visualisation BI.

08

Architecture Medallion

Architecture Medallion



Bronze

Données brutes JSON immutables.



Silver

Données nettoyées et validées.

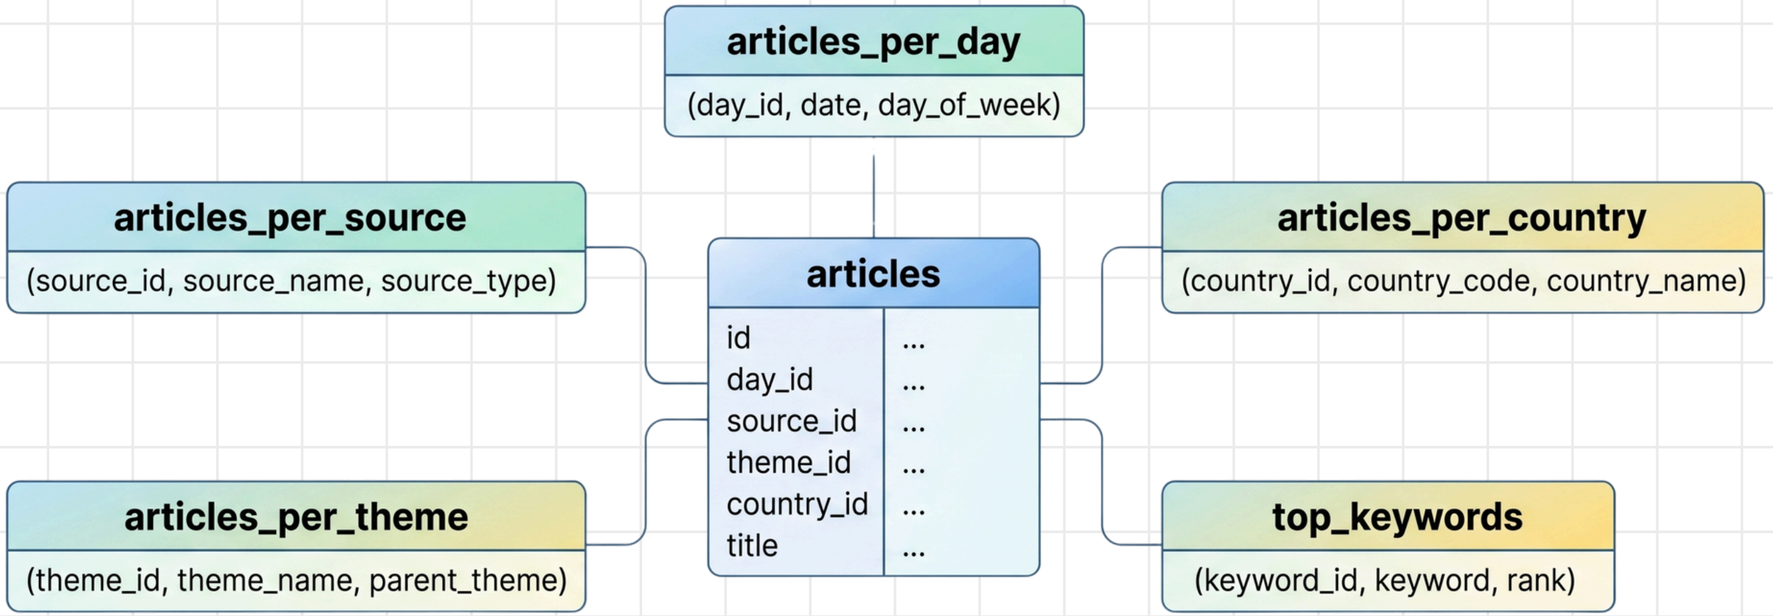


Gold

Agrégats analytiques optimisés.

09

Modèle de données



🔑 Pipeline idempotent

Clé primaire basée sur SHA1(url)

10

Ingestion

Ingestion



Scraper

BeautifulSoup + RSS multi-sources.



Kafka

Topic raw_articles pour découplage.



Cycle horaire

Exécution automatique configurable.

11

Qualité de données



Gate 1

Titre obligatoire



Gate 2

Date valide.



Gate 3

Contenu ≥ 100 caractères.



Rejet

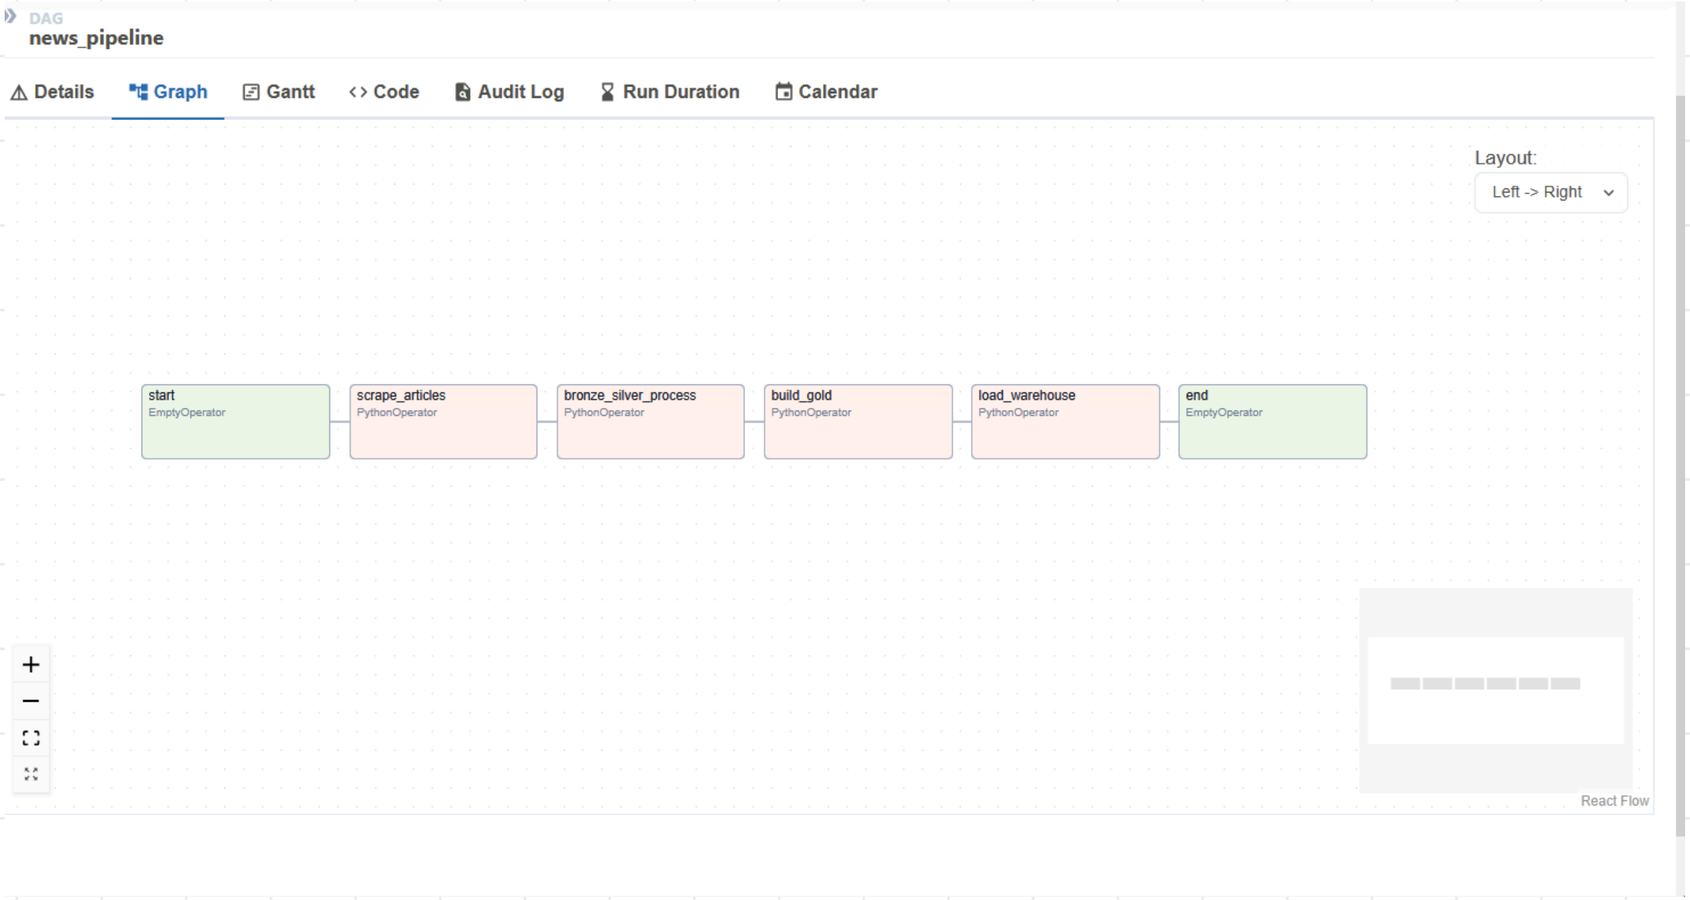
Aucune donnée perdue silencieusement.

12

Orchestration

Automatisation



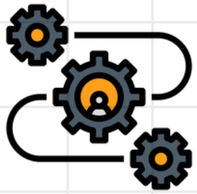


Schedule @hourly + retries automatiques

13

Visualisation

Visualisation



Tendances

BeautifulSoup + RSS multi-sources.



Analyse des sujets populaires.

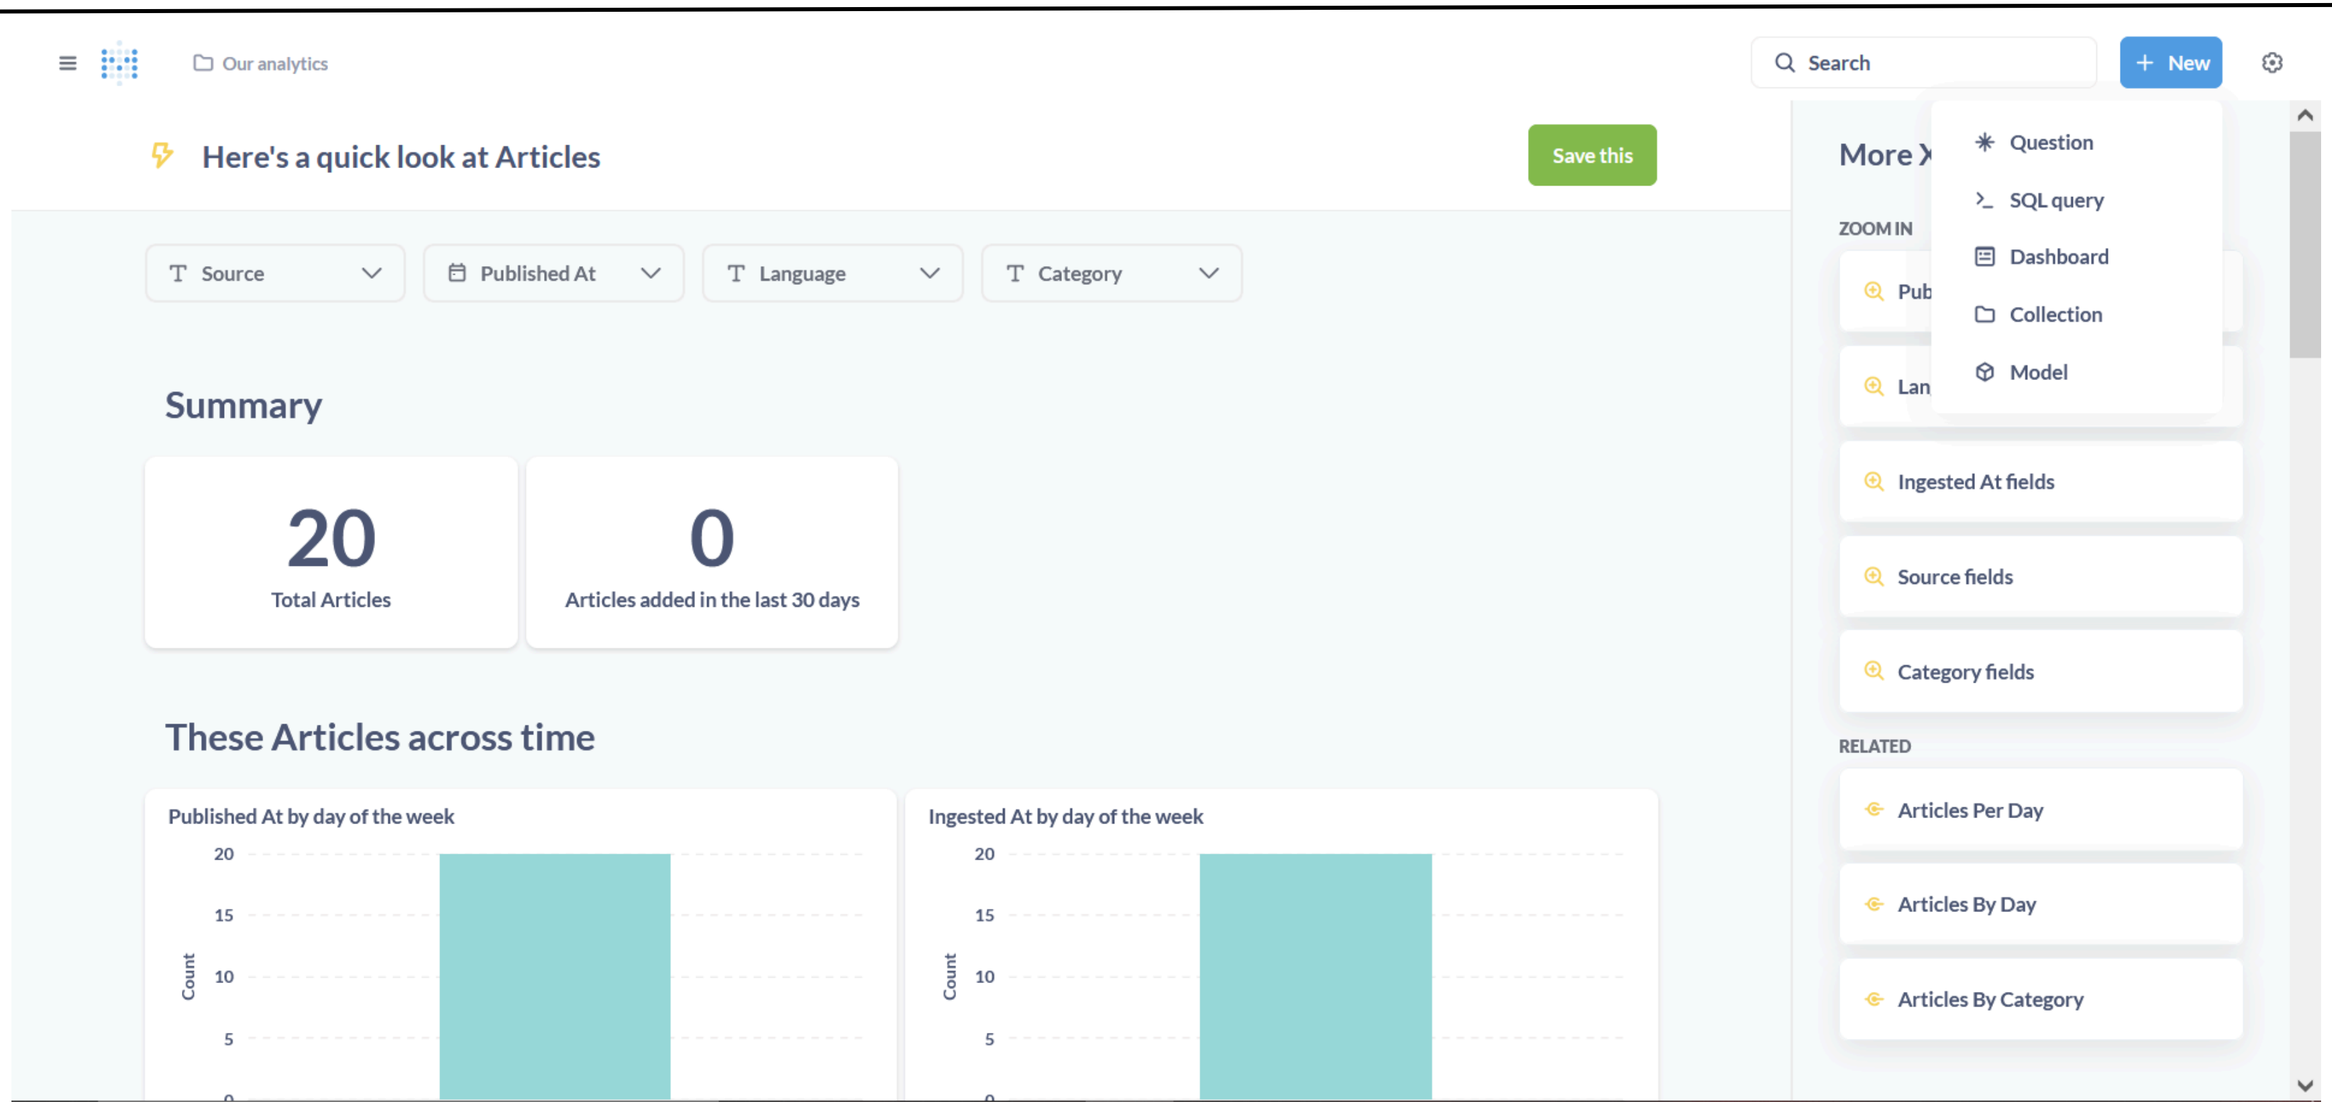
Répartition des articles par média.



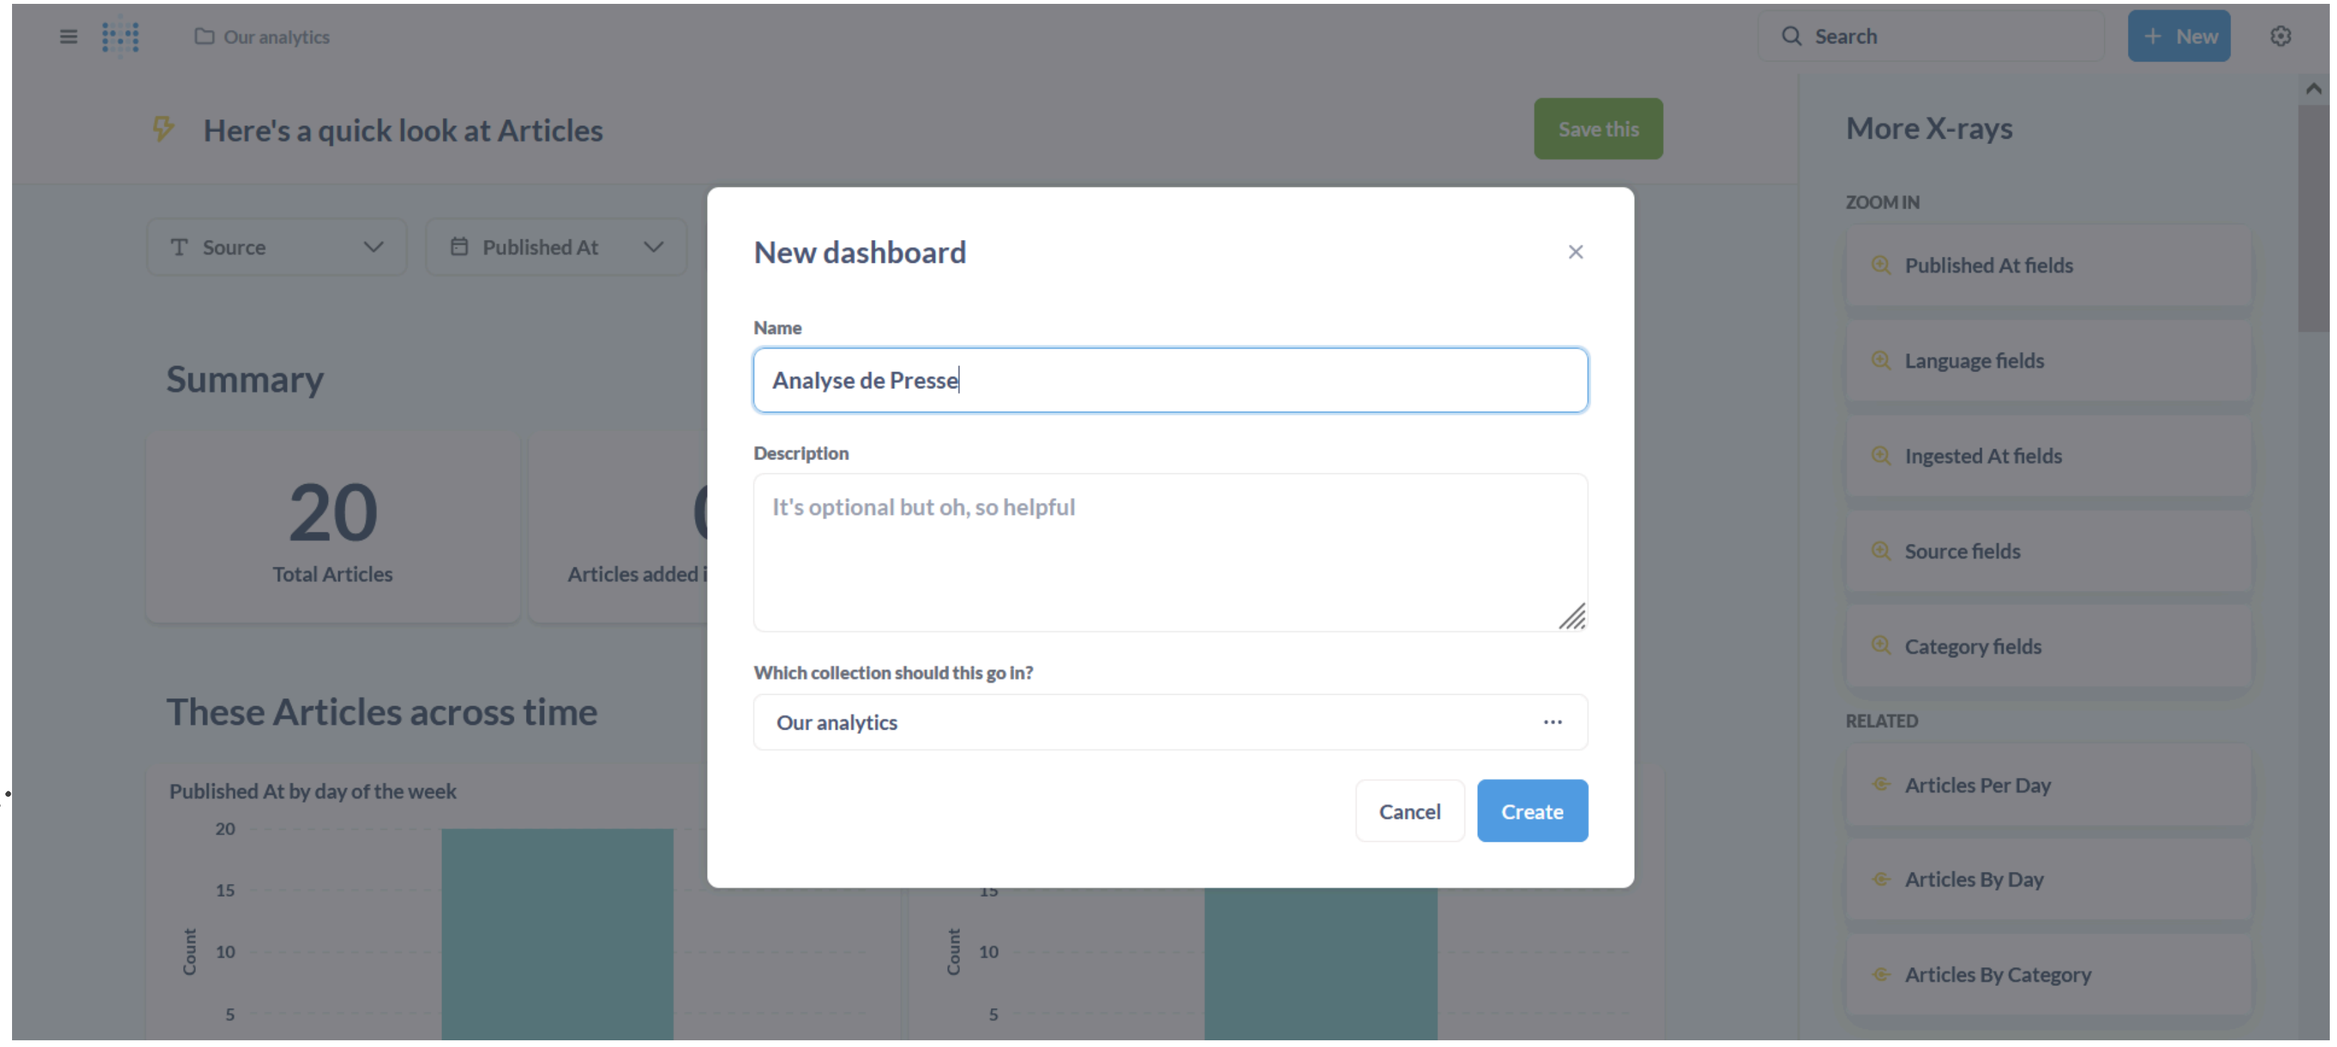
Mots-clés

Extraction des termes fréquents.

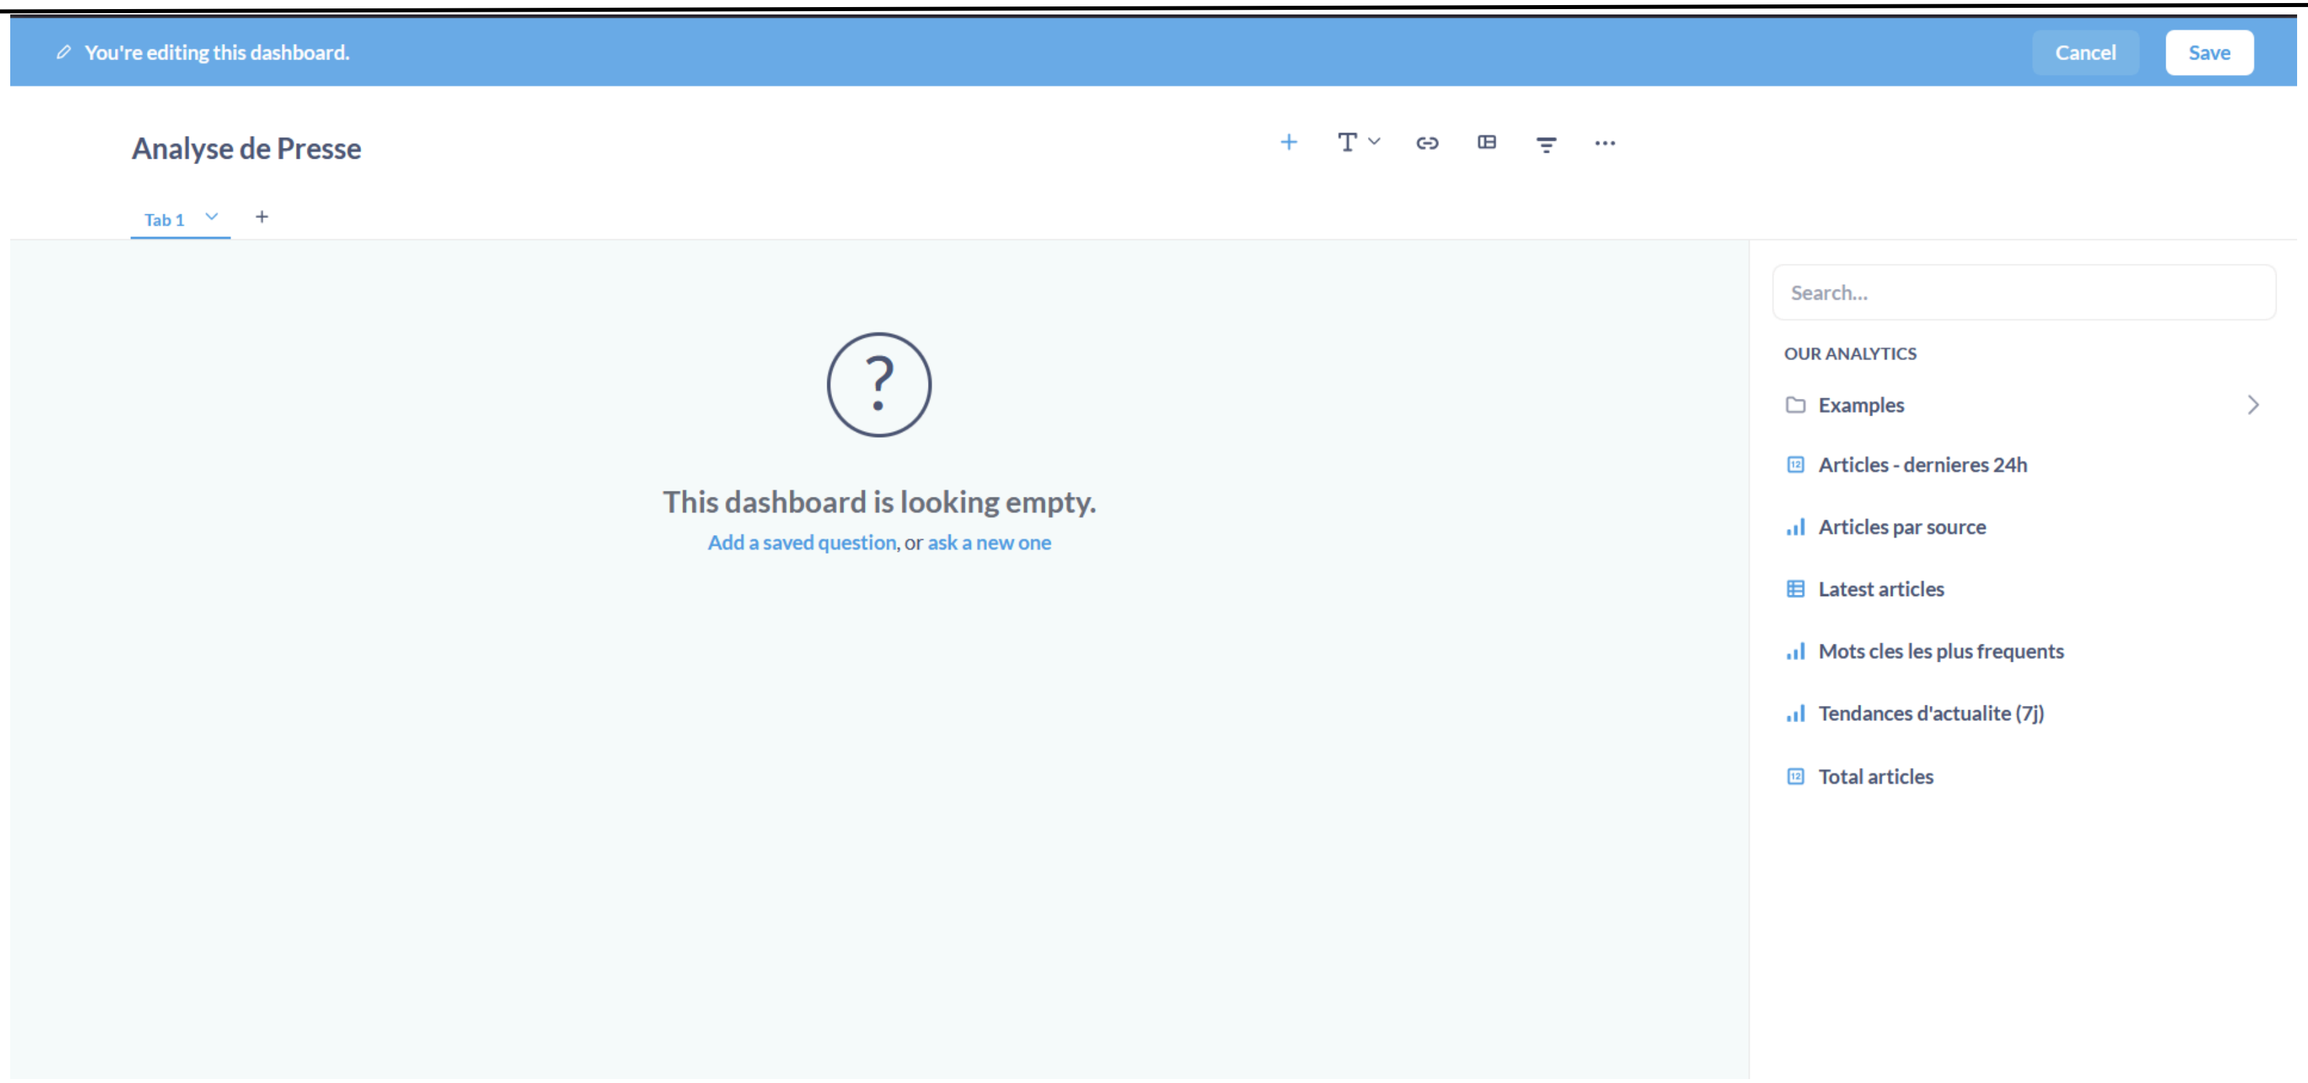
Visualisation



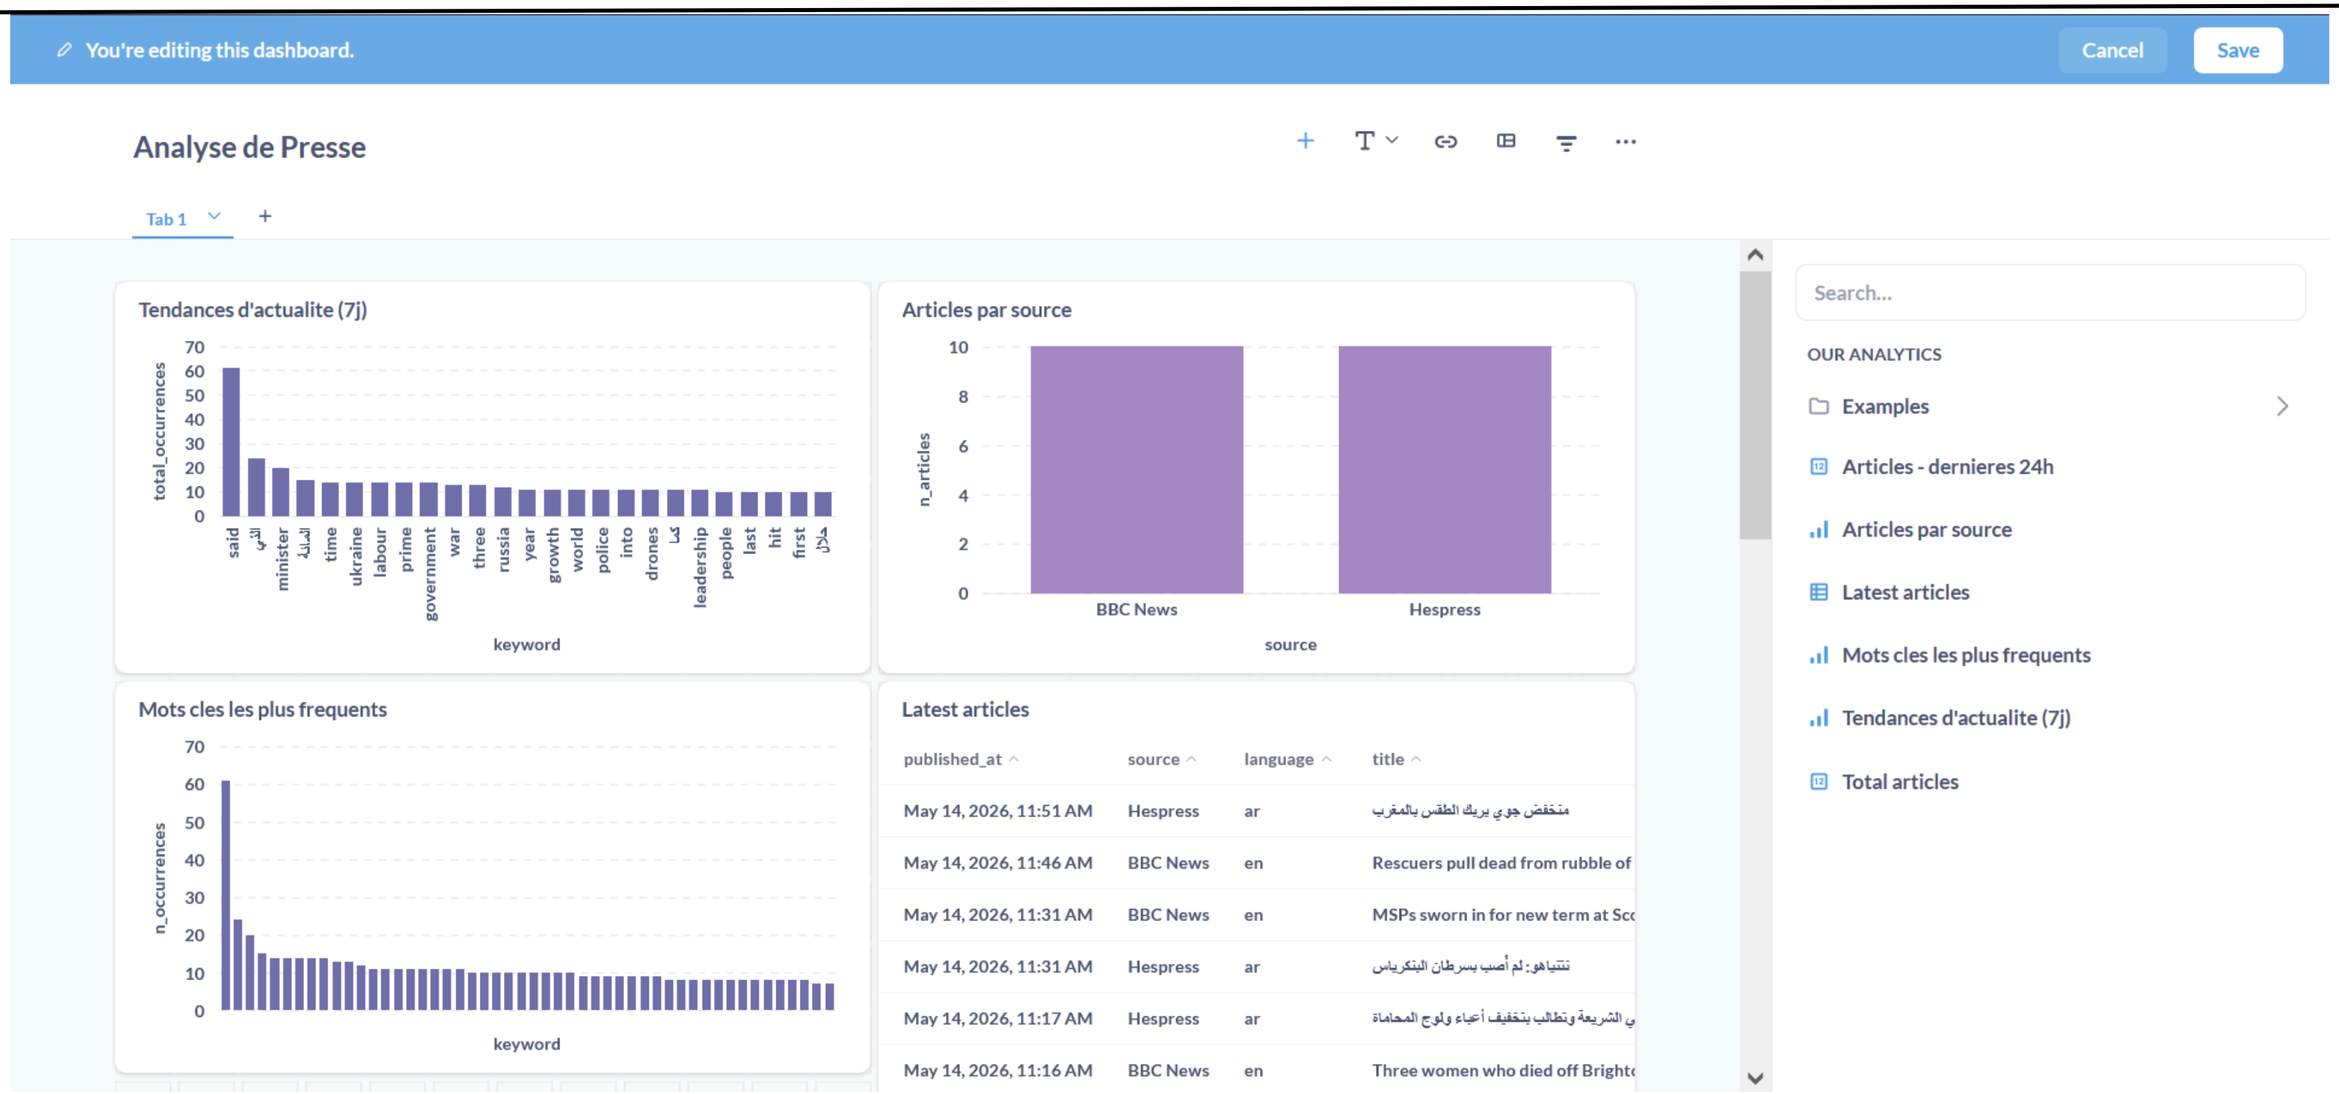
Visualisation



Visualisation



Visualisation



14

Démo live

14

Conclusion & perspectives



IA & NLP

NER et fake news detection.



Scalabilité

Migration future vers Spark.



Lineage

raçabilité avec OpenLineage.

MERCI

Do you have any questions?